

Capítulo 1: O Ponto de Partida - Decifrando o Desafio

A Missão Inicial

Nossa jornada começou com um desafio claro: nos foram entregues duas tabelas, JogadoresV1 e JogosV1, e uma missão: com base nelas, desvendar os segredos por trás de três colunas Target misteriosas. A orientação inicial sugeria um caminho direto: usar técnicas de clusterização e criar novas features para, então, prever os valores-alvo.

Mas será que esse era o primeiro passo a ser dado?

O Primeiro Obstáculo: Uma Linguagem Desconhecida

Antes de qualquer modelagem, nos deparamos com o primeiro obstáculo: um conjunto de dados com mais de 100 colunas cujos nomes, como V5Descr_0413 ou TipoJogoDescr_0101, eram verdadeiros enigmas. Era como tentar ler um livro em um idioma desconhecido.

Nossa primeira vitória foi decifrar esse código. Usando o arquivo JogosV1 como uma "pedra de Roseta", desenvolvemos uma lógica para traduzir sistematicamente esses nomes. Aos poucos, V5Descr_0413 se transformou em algo compreensível, como Quiz_Acertos, e os dados começaram a fazer sentido.

Tabela JogadoresV1 inicialmente:

Código de Acesso	F0101	F0102	F0103	F0104	F0201	Cor0202	F0203	Cor0204	F0205	Cor0206	F0207	Cor0208	Cor0209Outro	L0210 (não likert)
JDOL5ME75EKO	1	0	0,470588	3	1	FFFFFF	8	FFFFFF	2	FFFFFF	FFFFFF	FFFFFF	FFFFFF	0
CM3DF3GCO8KV	3	1	0,470588	3	2	BE845A	3	5B2600	2	FFFFFF	FFFFFF	262626	474747	0
CX7MQGTPWBVF	3	0	0,470588	2	5	FFFFFF	8	FFFFFF	2	FFFFFF	FFFFFF	FFFFFF	FFFFFF	5
GXZ25RE8L9UB	1	1	0,529412	1	0	CB869F	3	7F0D0D	2	41641F	000000	64451F	F2F2F2	0
1XSEM93HBL1W	2	0	0,470588	4	4	DEC29E	11	FFFFFF	2	FFFFFF	FFFFFF	FFFFFF	FFFFFF	5
21QPOX7EK9GB	3	0	0,529412	3	3	FACA7D	8	000000	2	8F8678	000000	000000	010100	0
3K07UCBRM7NJ	1	0	0,588235	2	2	FFFFFF	14	4F4545	2	FFFFFF	FFFFFF	FFFFFF	FFFFFF	5
PKT94846M7Z8	2	0	0,470588	3	5	947907	5	292929	2	AEAEAE	810000	3C3C3C	937600	2
7CG4949BWJOM	1	1	0,470588	1	2	FFFFFF	3	FFFFFF	1	FFFFFF	FFFFFF	FFFFFF	FFFFFF	5
LOSXY17C37Y	1	1	0,588235	2	0	FFFFFF	7	B30007	1	FFFFFF	FFFFFF	FFFFFF	FFFFFF	0
ZK2HP2Q1FWUT	4	1	0,588235	6	8	FFFFFF	13	FFFFFF	2	FFFFFF	FFFFFF	FFFFFF	FFFFFF	2
XU4DM426AR0G	4	0	0,470588	3	2	FFFFFF	2	FFFFFF	2	FFFFFF	FFFFFF	FFFFFF	FFFFFF	5
CK67CCD9KKZJ	3	0	0,352941	0	0	FFFFFF	0	FFFFFF	0	FFFFFF	FFFFFF	FFFFFF	FFFFFF	0
LN0OHX118GS8	1	0	0,470588	2	3	FFC6A1	8	5B5B5B	2	FFFFFF	4C4C4C	242424	212121	0
SL238SLJOF09	1	0	0,294118	2	3	FFFFFF	8	FFFFFF	2	0044FF	907300	000000	00FF00	2
WJ2MU06OBKPO	3	0	0,411765	2	2	B08A66	5	34141E	2	A00031	1F2449	8B1620	3E3B3B	0
9IGDF7ZDLI15	1	1	0,470588	1	0	FFFFFF	10	FFFFFF	2	FFFFFF	FFFFFF	FFFFFF	FFFFFF	2
97TP7GJA3HGF	3	0	0,470588	2	5	FFFFFF	5	FFFFFF	2	FFFFFF	FFFFFF	FFFFFF	FFFFFF	5
EN3ALMKV2XAH	1	0	0,470588	0	0	FFFFFF	0	FFFFFF	0	FFFFFF	FFFFFF	FFFFFF	FFFFFF	0
YZ9PZX2D9B6T	1	1	0,470588	2	0	F5D588	10	612119	1	FFFFFF	5B382B	383F76	FF5EBF	2
2U313TK7XGFP	1	0	0,411765	3	5	FFE8A1	8	FFFFFF	1	FFFFFF	D17410	2010D1	FFFFFF	5
ICWB0ZQ1IOGA	1	0	0,352941	2	2	FFFFFF	8	FFFFFF	2	FFFFFF	FFFFFF	FFFFFF	FFFFFF	5
RYB1ZLYWE1M9	1	1	0,352941	1	3	FFFFFF	10	FFFFFF	2	FFFFFF	FFFFFF	FFFFFF	FFFFFF	0
CBW1MWFYJT4S	3	1	0,294118	1	3	FFFFFF	2	FFFFFF	1	FFFFFF	FFFFFF	FFFFFF	FFFFFF	0

Tabela JogosV1 inicialmente:

ID	TipoJogoDescr	SubTipoJogo	V1	V1Descr	V2	V2Descr	V3	V3Descr	V4	V4Descr	V5	V5Descr	V6	V6Descr
0203	não likert; selecionado	03	0		1		2		3		4		5	
0204	Cor selecionada	04												
0205	não likert; selecionado	05	0		1		2							
0206	Cor selecionada	06												
0207	Cor selecionada	07												
0208	Cor selecionada	08												
0209	Cor selecionada	09												
0210	não likert; selecionado	10	1		2		3		4		5		6	
0211	Nome	11												
0299	Explicação	99												
0401	Qtd R corretas 1	01												
0402	Qtd R incorretas 1	02												
0403	Qtd R não selecionadas 1	03												
0404	Tempo 1	04												
0405	Qtd R corretas 2	05												
0406	Qtd R incorretas 2	06												
0407	Qtd R não selecionadas 2	07												
0408	Tempo 2	08												
0409	Qtd R corretas 3	09												
0410	Qtd R incorretas 3	10												
0411	Qtd R não selecionadas 3	11												
0412	Tempo 3	12												
0413	Qtd R corretas Total	13												
0414	Qtd R incorretas Total	14												

Organizando o Caos: A Classificação Visual

Com os nomes decifrados, ainda tínhamos uma planilha com dezenas de colunas. Antes mesmo de aprofundar no código, nosso próximo passo foi organizar esse caos. Abrimos a tabela e, como quem organiza um mapa, **agrupamos as colunas visualmente, atribuindo cores a cada categoria lógica**. Um tom para "Dados Demográficos", outro para "Preferências de Cor", e assim por diante.

Esse exercício manual, embora simples, foi fundamental. Ele nos deu uma primeira intuição sobre a estrutura dos dados e nos permitiu "sentir" onde as informações mais importantes poderiam estar escondidas.

Tabela modificada com as cores:

Código de Acesso	f0101	f0102	f0103	f0104	f0201	Cor0202	f0203	Cor0204	f0205	Cor0206	f0207	Cor0208	Cor0209	Outro	10210 (não lher)	f0299 - Explicação Tempo	Q0401	Q0402	Q0403	Q0404	Q0405	Q0406	Q0407	T0408	Q0409	Q0410	Q0411	T0412	Q0413	Q0414
JDLCLME752KX	1	0	56	3	1	FFFFFF	8	FFFFFF	2	FFFFFF	FFFFFF	FFFFFF	FFFFFF	0	N/A	10	1	3	63.602	5	4	9	47.394	8	1	3	0.0	23	6	
CM30F3GCO8KV	3	1	56	3	2	BE845A	3	5B2600	2	FFFFFF	FFFFFF	262626	474747	0	N/A	2	1	17	10.983	2	1	12	7.45	1	2	16	17.116	5	4	
CK7M0GTPW6VF	3	0	56	2	5	FFFFFF	8	FFFFFF	2	FFFFFF	FFFFFF	FFFFFF	FFFFFF	5	N/A	3	1	16	24.585	3	0	11	6.867	3	0	14	8.749	3	1	
GK225R6L9UB	1	1	57	1	0	CB863F	3	7F0C0D	2	4164F	000000	6445F	F0F2F2	0	N/A	2	4	17	55.815	1	5	13	60.465	2	1	15	26.766	5	10	
W5ENR93HBLW	2	0	56	4	4	DECC2E	11	FFFFFF	2	FFFFFF	FFFFFF	FFFFFF	FFFFFF	5	N/A	1	0	16	16.046	1	1	13	11.034	0	0	17	3.631	1	2	
21GPQK7EX9G5	3	0	57	3	3	FACA7D	8	000000	2	8F9876	000000	000000	010100	0	N/A	3	0	16	25.313	0	3	14	30.279	2	1	15	12.034	5	4	
3K07UCBRM7NJ	1	0	58	2	2	FFFFFF	14	4F4545	2	FFFFFF	FFFFFF	FFFFFF	FFFFFF	5	N/A	3	0	16	10.45	3	0	11	8.749	3	0	14	5.8	9	0	
PKT94848M7Z8	2	0	56	3	5	347307	5	232323	2	AEAEAE	010000	3C3C3C	337600	2	N/A	15	3	4	68.346	6	0	8	44.631	2	4	15	11.316	23	7	
7D349496WJQM	1	1	56	1	2	FFFFFF	3	FFFFFF	1	FFFFFF	FFFFFF	FFFFFF	FFFFFF	5	N/A	3	2	16	30.301	4	17	10	56.467	3	3	14	23.265	10	22	
LOSXVY7IC37Y	1	1	58	2	0	FFFFFF	7	830007	1	FFFFFF	FFFFFF	FFFFFF	FFFFFF	0	N/A	14	21	5	59.564	3	29	5	67.349	5	11	12	0.0	28	61	
ZK2HP2GIEVUT	4	1	58	6	8	FFFFFF	13	FFFFFF	2	FFFFFF	FFFFFF	FFFFFF	FFFFFF	2	N/A	17	1	2	49.463	13	2	1	43.955	9	1	8	28.9	39	4	
XU4DM426AROG	4	0	56	3	2	FFFFFF	2	FFFFFF	2	FFFFFF	FFFFFF	FFFFFF	FFFFFF	5	N/A	3	0	16	12.033	3	0	11	8.0	1	2	16	6.649	7	2	
CK67CCD9KXZJ	3	0	54	0	0	FFFFFF	0	FFFFFF	0	FFFFFF	FFFFFF	FFFFFF	FFFFFF	0	N/A	3	0	16	16.399	0	0	14	2.533	0	0	17	3.393	3	0	
LND0KH18G58	1	0	56	2	3	FFC6A1	8	56565B	2	FFFFFF	4C4C4C	242424	21C121	0	N/A	6	15	13	25.483	5	14	3	20.939	5	11	12	25.632	16	40	
SL236SLJQF09	1	0	53	2	3	FFFFFF	8	FFFFFF	2	0044FF	307300	000000	08FF2	2	N/A	3	0	16	21.716	3	0	11	14.359	3	0	14	17.518	3	0	
WJ2NMJ06GKPO	3	0	55	2	2	B08A66	5	34141E	2	A00031	F24449	881620	3E3E38	0	N/A	4	3	15	49.281	2	1	12	15.116	0	0	17	4.233	6	4	
96GDF7ZDLI5	1	1	56	1	0	FFFFFF	10	FFFFFF	2	FFFFFF	FFFFFF	FFFFFF	FFFFFF	2	N/A	7	1	12	41.149	0	6	14	55.63	2	0	15	13.749	9	7	
9TTP7GJA3HGF	3	0	56	2	5	FFFFFF	5	FFFFFF	2	FFFFFF	FFFFFF	FFFFFF	FFFFFF	5	N/A	0	4	19	57.048	0	0	14	2.6	0	0	17	1.783	0	4	
EN3ALMKV2XAH	1	0	56	0	0	FFFFFF	0	FFFFFF	0	FFFFFF	FFFFFF	FFFFFF	FFFFFF	0	N/A	0	0	19	5.817	0	0	14	3.25	0	0	17	2.333	0	0	
Y29F2XZD9B6T	1	1	56	2	0	F5D588	10	61C119	1	FFFFFF	5B382E	383F76	FF5EDF	2	N/A	19	4	0	62.347	12	0	2	55.147	14	0	3	0.0	45	4	
ZU31TK7XZEP	1	0	56	0	5	FFB6A1	8	FFFFFF	1	FFFFFF	01A101	2010D1	FFFFFF	5	N/A	3	0	16	15.649	3	0	11	6.9	3	0	14	10.183	3	0	
ICVB0ZD10GA	1	0	54	2	2	FFFFFF	8	FFFFFF	2	FFFFFF	FFFFFF	FFFFFF	FFFFFF	5	N/A	3	0	16	21.939	2	1	12	40.009	3	0	14	14.404	8	1	
RVB2LVVEM93	1	1	54	1	3	FFFFFF	10	FFFFFF	2	FFFFFF	FFFFFF	FFFFFF	FFFFFF	0	N/A	2	1	17	21.006	3	0	11	15.32	0	3	17	24.125	5	4	
CBW9MWPLYJ4S	3	1	53	1	3	FFFFFF	2	FFFFFF	1	FFFFFF	FFFFFF	FFFFFF	FFFFFF	0	N/A	3	0	16	39.015	1	2	13	19.199	2	2	15	22.899	6	4	
U0JD2Cv4JW0	3	0	54	1	0	F6B33C	2	FFFFFF	2	FFFFFF	FFFFFF	FFFFFF	FFFFFF	0	N/A	2	3	17	23.5	2	13	12	31.537	13	26	4	44.415	17	42	
00P1GHT19GT	3	1	54	2	2	FFFFFF	10	FFFFFF	1	FFFFFF	FFFFFF	FFFFFF	FFFFFF	5	N/A	14	0	5	34.649	12	0	2	26.816	14	0	3	27.965	40	0	
21WHLZGMV65	3	1	53	1	3	FFDD9A	3	7F6021	2	318EB9	8C399C	61EAF9	D620F6	5	N/A	19	34	0	95.845	10	27	4	0.0	0	0	17	0.0	29	61	
816G2WALZVY	1	0	56	0	5	FFFFFF	8	0F0C0D	1	FFFFFF	FFFFFF	FFFFFF	FFFFFF	5	N/A	0	0	19	10.283	0	0	14	5.433	0	0	17	1.7	0	0	
61K9DQZD1VNS	1	1	53	3	4	EEDF7E	10	F5DC47	2	34311E	776700	36CEB5	3648CE	5	N/A	8	0	11	31.565	2	5	12	20.499	5	0	12	23.049	15	5	
W4KJTTTSM06H	0	1	54	2	2	EEE497	7	000000	0	FFFFFF	000000	142EB8	070000	0	N/A	2	1	17	17.234	1	2	13	11.009	2	1	15	10.199	5	4	
10EYNUL30S5J	1	0	54	2	5	FFFFFF	11	FFFFFF	2	FFFFFF	FFFFFF	FFFFFF	FFFFFF	5	N/A	6	7	13	39.256	2	1	12	3.133	0	3	17	10.649	8	11	
9L9UE1GJH832	1	0	54	1	0	FFFFFF	8	FFFFFF	2	FFFFFF	FFFFFF	FFFFFF	FFFFFF	5	N/A	19	34	0	63.561	0	2	14	6.641	0	0	17	2.648	19	36	
A1RW3K9WLEBF	1	2	55	0	0	FFFFFF	0	FFFFFF	0	FFFFFF	FFFFFF	FFFFFF	FFFFFF	0	N/A	1	2	18	23.233	0	0	14	7.465	0	0	17	2.963	1	2	
YXFFER96XUN	0	1	53	2	0	F0F0AB	10	FFFFFF	0	FFFFFF	FFFFFF	FFFFFF	D151CD	5	N/A	3	0	16	14.363	3	0	11	3.866	3	0	14	3.216	3	0	
33Q6C9SL519	1	0	55	2	3	ESD2D0	3	849C96	1	655AA3	953A51	444C28	A64948	7	N/A	1	2	16	26.449	0	3	14	29.933	1	2	16	27.662	2	7	
MF9GSC23AUST	3	1	54	4	0	FFFFFF	10	FFFFFF	2	FFFFFF	FFFFFF	FFFFFF	FFFFFF	0	N/A	0	3	19	32.099	3	0	11	12.224	3	1	14	20.0	6	4	
173D6K81HJHJ	3	1	55	0	0	FFFFFF	10	D06EDC	0	FFFFFF	FFFFFF	8316AC	F032EF	0	N/A	2	2	17	55.464	0	1	14	7.85	3	0	14	13.85	5	3	

Legenda:

A	B	C
Legenda		
JOGO 1: Teste de Performance Progressivo		
JOGO 2: Quiz Multidimensional		
JOGO 3: Teste de Concentração/Memória de Trabalho		
Modo hard do Jogo acima		
Perfil		
Preferência e Personalidade		

A Escolha do Caminho: Entender Antes de Agir

Com os dados agora legíveis e visualmente organizados, a tentação de seguir a orientação inicial e saltar para a modelagem era grande. No entanto, acreditamos em um princípio fundamental: **primeiro, entender; depois, agir**.

Decidimos, então, mergulhar em uma **Análise Exploratória de Dados (EDA)** completa. Nosso objetivo era simples: transformar os números brutos em insights visuais. Queríamos que os dados contassem sua própria história através de gráficos antes que tentássemos forçá-los a se encaixar em um modelo.

As Primeiras Descobertas

Nossa exploração, documentada no notebook `TesteProjetoFinal.ipynb`, revelou uma realidade complexa e fascinante:


- A Necessidade de Ordem:** Descobrimos que muitas colunas que deveriam ser numéricas estavam formatadas como texto, e uma grande quantidade de dados estava simplesmente ausente. O primeiro passo foi uma limpeza meticulosa, convertendo os tipos de dados e tratando os valores nulos para criar uma base de trabalho confiável.
- O Poder da Agregação:** Em vez de nos perdemos em dezenas de colunas individuais de performance ou opinião, criamos novas features que resumiam o

comportamento do jogador. Nasceram assim métricas poderosas como Quiz_Taxa_de_Acerto, Performance_Score_Medio e Likert_Score_Medio.

3. **Os Dados Começam a Falar:** Foi então que os gráficos começaram a nos contar os primeiros segredos.
 - Um **mapa de calor** revelou que nossas novas features agregadas tinham uma correlação promissora com as colunas Target. Havia um sinal claro ali.
 - Um **gráfico de dispersão** tornou a relação ainda mais evidente, mostrando uma tendência de que jogadores com uma Quiz_Taxa_de_Acerto mais alta tendiam a ter um Target1 também mais alto. A história começava a tomar forma.

Visão geral dos dados:

Visão Geral dos Dados



O Fim do Começo

Ao final desta primeira etapa, não tínhamos ainda um modelo preditivo, mas possuíamos algo muito mais valioso: **clareza**. Transformamos dados brutos e confusos em um conjunto de informações organizadas, com features poderosas e, o mais importante, com uma compreensão visual dos padrões que ali se escondiam.

A jornada de exploração havia terminado, e a de modelagem estava prestes a começar. Estávamos agora prontos para o próximo passo, armados não com suposições, mas com os insights que os próprios dados nos forneceram.

Capítulo 2: Da Exploração à Estratégia - O Primeiro Sprint

Organizando a Jornada

Com a clareza obtida na exploração inicial, nossa equipe estava pronta para avançar com mais estrutura e método. Adotando uma **metodologia ágil** e organizando nossas tarefas no Trello, iniciamos nosso primeiro *Sprint* com objetivos bem definidos: transformar a análise em ação e traçar um plano de modelagem baseado em evidências sólidas.

Quadro Kanban utilizado durante o projeto:



Domando a Complexidade dos Dados

O primeiro passo foi consolidar o trabalho de decodificação. Conforme documentado em nosso notebook de sprint (Projeto_Desafio_Final_Daruma_Grupo_1_(Sprint_1).ipynb), o desafio de traduzir **114 colunas** enigmáticas foi superado, resultando em um dataset legível e pronto para a análise.

A análise de qualidade nos mostrou que nem todos os dados eram igualmente valiosos. Tomamos nossa primeira decisão executiva de limpeza: **colunas com mais de 90% de valores ausentes foram removidas**. Essa ação simplificou nosso universo de análise, permitindo focar no que realmente importava. Também flagramos anomalias, como tempos com valores negativos, que foram catalogadas para tratamento no próximo Sprint.

Análise feita sobre as colunas:

```
--- Análise de Dados Faltantes ---
As 10 colunas com maior porcentagem de dados faltantes:

```

	quantidade_nulos	porcentagem_nulos
F0299_-_Explicacao_Tempo	183	100.000000
T1205Expl	183	100.000000
T1199Expl	183	100.000000
TempoTotalExpl	179	97.814208
PTempoTotalExpl	176	96.174863
T1210Expl	161	87.978142
T0499_-_Explicacao_Tempo	157	85.792350
Target1	10	5.464481
Target3	10	5.464481
Target2	10	5.464481


Estratégia para o Sprint 2: Colunas com mais de 90% de dados faltantes (como 'F0299_-_Explicacao_Tempo') serão candidatas à remoção.

Revelando os Primeiros Insights de Negócio

Com os dados mais limpos, começamos a enxergar o comportamento dos nossos jogadores com mais nitidez.

- **Perfil de Uso:** A análise revelou uma concentração clara de atividade nos jogos do **Tipo 1 (59 sessões)** e **Tipo 3 (58 sessões)**. Um insight particularmente interessante foi a expressiva quantidade de sessões da **categoria "0" (49 sessões)**, levantando a hipótese de que estas podem ser sessões de tutorial ou interações incompletas — um ponto crucial para entender o engajamento inicial do usuário.

Gráfico do número de sessões registradas por tipo de jogo:




A Descoberta Chave que Mudou o Rumo do Projeto


A análise de correlação, realizada no notebook, foi o verdadeiro ponto de virada do nosso projeto. Ela nos deu as primeiras pistas concretas sobre o que influenciava nossos Targets.

- **Fatores de Influência para o Target1:** Para o Target1, dois protagonistas emergiram dos dados. A feature TipoJogoDesc_0713 mostrou uma **forte correlação positiva (+0.42)**, enquanto a TempoTotalExp1 revelou uma **correlação negativa ainda mais impactante (-0.67)**. Tínhamos, pela primeira vez, uma indicação clara dos principais "interruptores" que afetam o resultado de um jogador.

TOP 15 Features com Correlação POSITIVA com os Targets:



Features com Correlação NEGATIVA com os Targets (ignorando valores nulos):



Mas a descoberta mais importante — aquela que definiu toda a nossa estratégia futura — veio ao compararmos o comportamento dos três targets. Percebemos que uma feature que influenciava positivamente o Target1 poderia ter um efeito neutro ou até **negativo** no Target2.

Os targets não se comportavam da mesma maneira.

A Nova Estratégia: Um Time de Especialistas

Essa revelação foi decisiva. Ficou claro que um modelo único e "generalista", que tentasse prever os três targets de uma vez, seria ineficiente e impreciso. Ele estaria constantemente em um "cabo de guerra", onde a otimização para um alvo prejudicaria o outro.

A solução seria criar um time de "especialistas".

Nossa estratégia para o Sprint 2 foi definida ali: em vez de um modelo, construiremos **três modelos distintos e especializados**, um para cada target. Cada modelo será treinado e

otimizado para sua tarefa específica, uma abordagem que promete uma precisão muito maior.

Conclusão do Sprint 1: Este primeiro Sprint nos levou da simples exploração a uma estratégia de modelagem clara e orientada por dados. Transformamos um mar de colunas confusas em insights de negócio e, o mais importante, em um plano de ação concreto. Com a estratégia definida, o próximo passo é iniciar a construção do nosso primeiro modelo especialista.

Capítulo 3: Mapeando o DNA do Jogo - A Estratégia Definitiva

De Colunas a Conceitos: A Estruturação Final

Com a clareza da exploração inicial, nosso foco se voltou para a arquitetura da própria experiência do jogador. O primeiro marco deste Sprint foi concluir a fase de estruturação do dataset. O desafio de decodificar as colunas foi superado, resultando em um dataset robusto com **107 colunas com nomes únicos e descritivos**, uma base sólida para qualquer análise futura.

A Descoberta dos 5 Módulos de Jogo

A análise aprofundada da nomenclatura das colunas confirmou uma hipótese fundamental: os dados não eram uma lista aleatória de variáveis, mas estavam organizados em **5 módulos de atividade distintos** (como Módulo de Quiz, Módulo de Performance Progressiva, etc.). Mapear essa estrutura foi a chave que abriu a porta para uma engenharia de features muito mais inteligente e contextualizada.

Para validar essa tese, realizamos uma prova de conceito focada no "Módulo de Quiz", criando as métricas Quiz_Taxa_de_Acerto e Quiz_Tempo_Total. O sucesso foi imediato, provando que a estratégia de agregar dados por módulo era o caminho certo.

As Peças se Encaixam: Preditores-Chave e a Confirmação da Estratégia

Com o dataset limpo e enriquecido, realizamos a análise de correlação definitiva. As visualizações, separadas para cada Target, revelaram os preditores-chave com uma clareza sem precedentes:

- **Para Target1:** A análise mostrou uma forte influência positiva de TipoJogoDesc_0713 (**+0.40**) e uma influência negativa ainda mais forte da hora de acordar, Acordar (**-0.61**).
- **Para Target2:** O padrão se repetiu com TipoJogoDesc_0713 (**+0.32**), mas o maior impacto negativo veio de outra variável de feedback, TipoJogoDesc_1107 (**-0.57**).
- **Para Target3:** O cenário mudou drasticamente. A maior influência positiva veio de TipoJogoDesc_1103 (**+0.59**), enquanto TipoJogoDesc_0713, que era positiva para os outros, aqui mostrou um efeito negativo (**-0.42**).

Este último ponto foi a prova final e irrefutável: as features tinham **efeitos diferentes e até opostos** em cada target. A estratégia de **modelos especialistas**, um para cada alvo, não era apenas uma boa ideia, era a única abordagem correta.

O Plano de Ação: A Estratégia de Modelagem para o Sprint 2

Com base nessas descobertas, definimos um plano de ação claro e multifacetado para o próximo Sprint, consolidando nossa estratégia de modelagem:

1. **Pré-processamento Diferenciado:** Aplicaremos escalonadores distintos para garantir que os modelos não sejam influenciados pela escala das variáveis, usando `RobustScaler` para features com outliers e `StandardScaler` para as demais.
2. **Engenharia de Features Avançada:** Vamos expandir o sucesso da prova de conceito para **todos os 5 módulos de jogo**, criando um arsenal de features agregadas (ex: `Performance_Progressiva_Score_Medio`) para potencializar os modelos.
3. **Modelagem Preditiva Especializada:** Construiremos **três modelos de regressão distintos**, um para cada target, usando um conjunto otimizado de features.
4. **Modelagem de Clusterização (em paralelo):** Utilizaremos as novas features agregadas para treinar um modelo de clusterização (K-Means) e, finalmente, definir os perfis ou "personas" dos jogadores.
5. **Desenvolvimento do Dashboard:** Iniciaremos a prototipação da interface que integrará e dará vida a todos os resultados.

Conclusão: Ao final deste Sprint, saímos de uma hipótese para uma estratégia de modelagem completa, detalhada e validada por dados. Mapeamos a estrutura do jogo, provamos nosso conceito de engenharia de features e temos um plano de ação claro para a fase mais aguardada do projeto: a construção dos modelos. Com essas peças-chave identificadas, o mapa estava traçado. Estávamos confiantes de que, para cada Target, tínhamos os ingredientes certos. O próximo passo lógico era óbvio: usar esses ingredientes para construir nossos primeiros modelos preditivos e testar nossa hipótese na prática.

Capítulo 4: Resultados e a Jornada de Otimização)

A Estratégia de Otimização: Da Força Bruta à Inteligência

Com o plano de criar um modelo especialista para cada Target, a próxima pergunta era: quais das mais de 100 features disponíveis seriam as mais importantes? Uma abordagem de "força bruta" correria o risco de criar modelos complexos e "viciados" (overfitting).

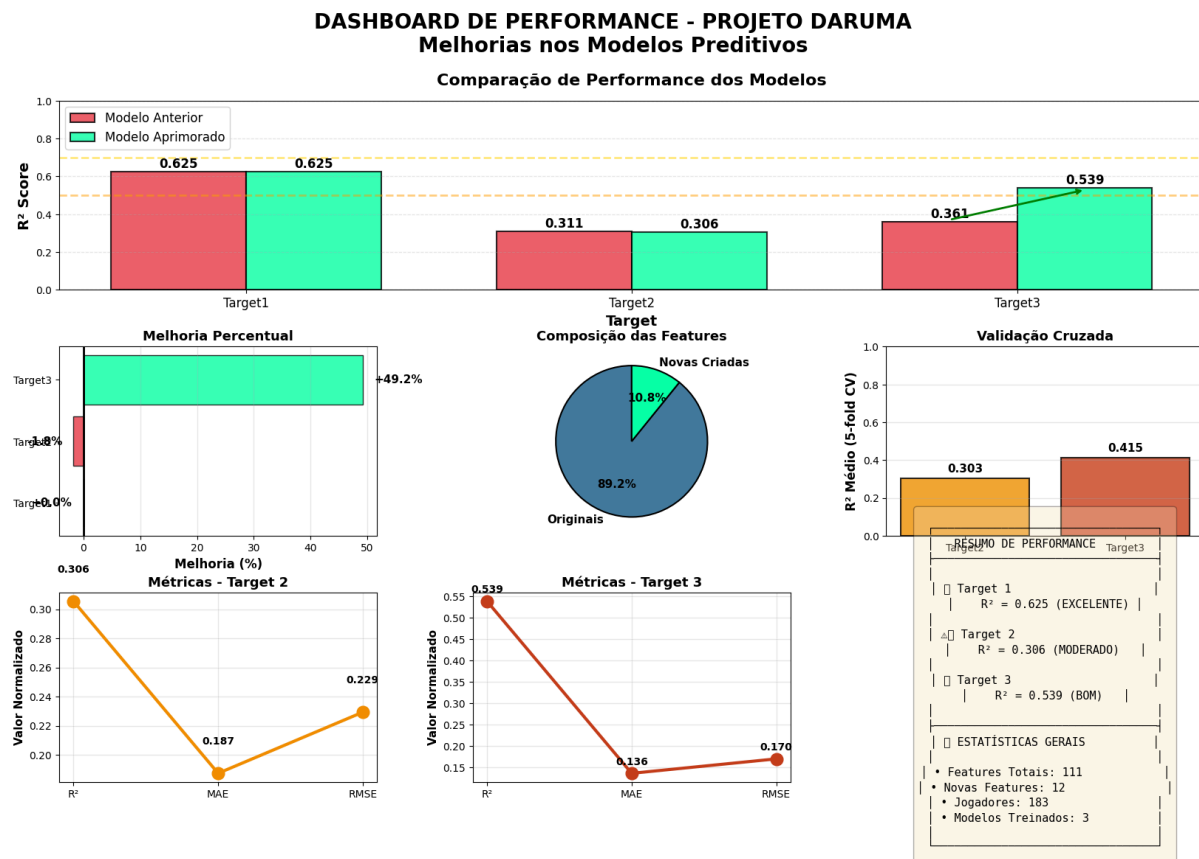
Decidimos por uma abordagem mais científica. Conforme implementado em nosso notebook, utilizamos a técnica de **Seleção Recursiva de Features (RFE)**. Em vez de adivinharmos, o RFE testa sistematicamente diferentes combinações para descobrir o número exato de features que maximiza a performance de cada modelo.

Os Resultados: Uma História de Persistência e Refinamento

A execução da modelagem nos levou por uma jornada de descobertas e ajustes.

- **Target 1: O Sucesso Imediato** Desde o início, o modelo para o Target1 mostrou-se um sucesso. A abordagem inicial já nos entregou um resultado forte e confiável, validando nossa estratégia.
- **O Desafio com Target 2 e 3: A Necessidade de uma Nova Abordagem** No entanto, nossos testes iniciais para o Target2 e Target3 **não apresentaram resultados convincentes**. Os valores de acurácia eram baixos e indicavam que os modelos não estavam capturando os padrões desses alvos de forma eficaz. Ficou claro que uma abordagem "tamanho único" para a modelagem, mesmo com modelos separados, não seria suficiente.
Diante desse desafio, decidimos **testar uma abordagem diferente e mais refinada especificamente para estes dois targets**. Voltamos à prancheta, reavaliamos a seleção de features e ajustamos os parâmetros dos modelos. Foi um processo iterativo, focado em encontrar a combinação certa que finalmente "destravasse" o potencial preditivo para esses alvos mais complexos.
- **O Clímax: Os Resultados Finais** A persistência valeu a pena. Após a aplicação da nova abordagem, os resultados finais de acurácia (medidos pelo R^2) contaram a história do nosso sucesso:
 - **Target 1: $R^2 = 0.625$ - BOM** (Mantendo a forte performance inicial).
 - **Target 3: $R^2 = 0.539$ - BOM** (Um salto de qualidade significativo após a nova abordagem).
 - **Target 2: $R^2 = 0.306$ - MODERADO** (Ainda o mais desafiador, mas com uma melhoria que estabelece um sinal preditivo claro e um ponto de partida para futuros Sprints).

Melhoria dos Target 2 e Target 3 comparado a seus resultados anteriores:




Além da Predição: A Descoberta das Personas de Jogadores

Em paralelo, cumprimos um dos objetivos estratégicos do nosso plano: entender não apenas "o quê" os jogadores fariam, mas "quem" eles eram. Usando as poderosas features agregadas que criamos a partir dos 5 módulos de jogo, aplicamos um modelo de clusterização **K-Means**.

O resultado foi a identificação de **4 "personas" de jogadores distintas**, cada uma com um perfil de comportamento claro:

- **Persona 0 ("Os Engajados")**
- **Persona 1 ("Os Desafiados")**
- **Persona 2 ("Os Metódicos")**
- **Persona 3 ("Os Especialistas")**

Método cotovelo utilizado para determinar a quantidade de personas (A maior queda define a quantidade de clusters):



Aprendendo com os Erros: O Valor da Análise Crítica

Um modelo só é verdadeiramente compreendido quando conhecemos suas falhas. Na fase final, realizamos uma **análise de erros**, investigando os casos em que os modelos mais falharam. Essa análise nos forneceu um feedback valioso e um roteiro claro para os próximos Sprints de refinamento, especialmente para o Target2.

Conclusão do Capítulo: Este Sprint foi uma verdadeira jornada de modelagem. Não apenas construímos nossos modelos especialistas, mas também enfrentamos e superamos desafios, refinando nossa abordagem para alcançar resultados significativos. O sucesso

com Target1 e Target3 e a descoberta das personas de jogadores representam um avanço imenso, enquanto o desafio contínuo do Target2 nos dá um foco claro para o futuro.

Confirmando a Estratégia: O Sucesso e o Desafio dos Especialistas

A construção dos nossos primeiros modelos especialistas foi a prova de fogo para a estratégia que definimos no Sprint anterior. Os resultados confirmaram nossa hipótese, mas também revelaram a complexidade da jornada que tínhamos pela frente.

- **O Sucesso Imediato do Target 1** validou nossa abordagem: ao focar em um único alvo com um modelo dedicado, alcançamos um resultado forte e confiável desde o início.
- **O Desafio com os Targets 2 e 3**, no entanto, mostrou que, mesmo com modelos especialistas, a tarefa não seria trivial. Os resultados iniciais, embora melhores que uma abordagem generalista, ainda eram modestos, indicando que esses alvos possuíam padrões mais complexos e sutis.

Ficou claro que estávamos no caminho certo, mas a jornada de otimização estava apenas começando. Tínhamos validado a estratégia, e agora o desafio era refinar a execução.

Capítulo 5: O Ponto de Virada - Um Novo Nível de Exigência

A Apresentação e o Choque de Realidade

Após a construção bem-sucedida dos nossos primeiros modelos especialistas, com resultados que considerávamos promissores e uma compreensão crescente sobre o comportamento dos jogadores, apresentamos nosso progresso. Estávamos confiantes de que a estratégia dos modelos individuais e a descoberta das "personas" seriam vistas como um grande avanço.

Foi nesse momento que a nossa jornada encontrou seu primeiro grande ponto de virada: um feedback que, embora duro, foi fundamental para redefinir nossas metas e nossa compreensão do problema.

O Desafio Triplo: As Novas Diretrizes do Projeto

O feedback que recebemos pode ser resumido em três desafios principais, que nos forçaram a reavaliar toda a nossa estratégia:

1. **O Desafio da Performance: "Bom" Não Era o Bastante.** Fomos informados de que, embora nossos modelos fossem um começo sólido, a acurácia (R^2) alcançada – na casa de 0.625 para o melhor modelo – ainda não era suficiente para as necessidades do projeto. A meta foi redefinida e a barra, elevada: o mínimo aceitável para um modelo ser considerado de valor seria um **R^2 de 0.700**.

2. **O Desafio do Foco: Predição Individual Acima de Tudo.** Nossa descoberta das "personas" de jogadores através da clusterização, que considerávamos um insight valioso sobre o comportamento do grupo, foi questionada. Foi reforçado que o objetivo principal e inegociável do projeto era prever **valores individuais** com a máxima precisão possível. A criação de clusters, embora interessante, foi considerada uma distração deste foco central.
3. **O Desafio da Complexidade: O Paradigma das Features.** Talvez o feedback mais contra-intuitivo tenha sido sobre nossa estratégia de reduzir drasticamente o número de features para combater o overfitting. A crítica foi que, ao simplificar demais o modelo, poderíamos estar descartando informações e interações valiosas que só uma máquina poderia encontrar. O argumento era que a força do Machine Learning está justamente em sua capacidade de **analisar uma quantidade de dados que um ser humano não conseguiria**, e nossa abordagem de "menos é mais" ia contra esse princípio fundamental.

Reavaliando a Estratégia: Um Novo Caminho a Seguir

Esse feedback foi um choque de realidade, mas também um presente. Ele nos forçou a sair da nossa zona de conforto e a questionar nossas próprias premissas sobre o que significava "um bom modelo".

Entendemos que não bastava ter um modelo que "funcionasse"; precisávamos de um modelo que atingisse um patamar de excelência. Para isso, tínhamos que mudar nossa abordagem radicalmente.

O novo plano de ação foi traçado com base nessas diretrizes:

1. **Busca por Performance Máxima:** Nosso foco absoluto será em técnicas mais avançadas de engenharia de features e uma otimização de hiperparâmetros ainda mais exaustiva para tentar quebrar a barreira do R^2 de 0.700.
2. **Foco Total na Regressão:** A modelagem de clusterização será pausada. Todos os nossos esforços serão direcionados para aumentar a precisão dos modelos de regressão individuais.
3. **Abraçando a Complexidade (com Controle):** Vamos reavaliar nossa estratégia de seleção de features. Em vez de buscar o modelo *mais simples*, buscaremos o modelo com o *melhor equilíbrio entre a utilização de muitas features e a generalização*. Isso significa explorar modelos que possam lidar com um grande número de variáveis, mas aplicando técnicas de regularização ainda mais fortes para controlar o overfitting.

Conclusão do Capítulo: Este feedback não foi um ponto final, mas o início de um novo capítulo em nossa jornada. Com metas mais ambiciosas e uma compreensão mais clara das expectativas, voltamos à prancheta, não com menos confiança, mas com um foco renovado. O próximo Sprint não seria apenas mais uma etapa. Seria a nossa resposta a esse desafio. Uma ofensiva total para quebrar a barreira do 0.700 e transformar a pressão em nosso maior sucesso.

Capítulo 6: A Grande Ofensiva - A Busca Implacável pelo 0.700

Uma Força-Tarefa Unificada

O desafio estava lançado: alcançar um R^2 de 0.700. A meta era ambiciosa e, diante da sua magnitude, algo novo aconteceu. As barreiras entre as diferentes equipes do projeto se dissolveram. O que antes eram esforços separados se tornou uma **força-tarefa unificada**, com todos os talentos e ideias focados em um único e formidável objetivo. Este não era mais um projeto de um grupo; era uma missão de todos.

Decifrando o Jogo em Nossos Próprios Termos

Percebemos que para extrair o máximo dos dados, precisávamos de um entendimento que fosse além do dicionário original. O primeiro passo desta nova fase foi um mergulho profundo nos dados para construir a **nossa própria legenda**. Analisamos coluna por coluna, comportamento por comportamento, e criamos um dicionário de dados detalhado, nascido da nossa experiência acumulada. Este artefato se tornou nossa nova "pedra de Roseta", garantindo que cada teste e cada modelo fossem construídos sobre uma base de conhecimento sólida e unificada.

Legenda criada pela nossa análise:

Dicionário de Dados - Classificação das Colunas

1. IDENTIFICAÇÃO

Coluna	Tipo	Descrição
Código de Acesso	Texto	Identificador único do participante
Data/Hora Último	DateTime	Data e hora do último registro

2. DADOS DEMOGRÁFICOS (F01XX)

Coluna	Tipo	Descrição
F0101	NãoLikert	Gênero (0-5)
F0102	NãoLikert	Binário (0/1)
F0103	NãoLikert	Idade (53-84 anos)
F0104	NãoLikert	Categoria numérica (0-6)

3. PREFERÊNCIAS DE COR (F02XX / Cor02XX)

Coluna	Tipo	Descrição
F0201	NãoLikert	Escala 0-8
Cor0202	Texto	Código hexadecimal de cor
F0203	NãoLikert	Escala 0-14
Cor0204	Texto	Código hexadecimal de cor

A Batalha dos Modelos: Uma Busca Exaustiva

Com a nova legenda em mãos e o objetivo claro, lançamos uma ofensiva de modelagem em múltiplas frentes. Nossos notebooks, como o `testeModelos.ipynb` e o `TesteReformulado.ipynb`, se tornaram campos de batalha onde testamos exaustivamente o arsenal do machine learning.

- Foram testados **mais de 15 algoritmos diferentes**, desde modelos lineares clássicos como Ridge e Lasso, até ensembles complexos e poderosos como RandomForest, Gradient Boosting, XGBoost e LightGBM.
- Não nos limitamos a testar apenas modelos. Exploramos diferentes estratégias de pré-processamento, novas formas de engenharia de features e diversas técnicas de regularização, buscando qualquer otimização que pudesse nos aproximar da meta.

A Muralha do 0.700

Apesar da colaboração massiva e da variedade de técnicas testadas, um padrão frustrante começou a emergir. Modelo após modelo, teste após teste, os resultados invariavelmente atingiam um platô. Conseguíamos scores de R^2 na faixa de 0.55, 0.60, às vezes um pouco mais, mas a barreira do 0.700 permanecia inatingível, como uma muralha intransponível.

Matriz de desempenho final dos modelos:

--- Matriz de Desempenho Final dos Modelos ---					
	Target	Modelo	R^2 Treino	R^2 Teste	Cumpriu Critério (≥ 0.700)
0	Target 1	Linear Regression	0.716342	-0.010000	Não
1	Target 1	XGBoost	1.000000	0.263711	Não
2	Target 2	Linear Regression	0.716342	-0.010000	Não
3	Target 2	XGBoost	1.000000	0.263711	Não
4	Target 3	Linear Regression	0.716342	-0.010000	Não
5	Target 3	XGBoost	1.000000	0.263711	Não

A conclusão, embora difícil, era inevitável: com as features e a abordagem de modelagem atuais, **parecia impossível alcançar a meta estipulada**.

A Revelação: Quando Mais do Mesmo Não é a Resposta

Essa muralha nos ensinou a lição mais valiosa do projeto até então. O esforço monumental nos provou que a solução para o nosso problema provavelmente não estava em encontrar um algoritmo "mágico" ou em mais um ajuste fino de hiperparâmetros. Tentar mais um modelo diferente seria apenas mais do mesmo.

O gargalo não estava na *modelagem*, mas sim na *matéria-prima*: as **features**.

Percebemos que havíamos atingido o limite do que as features atuais poderiam nos dizer. Para quebrar a barreira do 0.700, não precisávamos de um modelo melhor, precisávamos de **informações melhores**.

A Revelação: O Problema não era o Motor, mas o Ruído nos Dados

A muralha do 0.700 nos ensinou a lição mais valiosa do projeto. Após testar exaustivamente desde modelos simples até os mais poderosos do mercado, como Gradient Boosting e XGBoost, o resultado era o mesmo: um platô de performance e, pior, sinais claros de instabilidade e overfitting (como visto na Matriz de Desempenho, onde o R^2 de treino era 1.0 e o de teste era pífio, como 0.26). A conclusão era inevitável: o gargalo não estava na complexidade do modelo. Pelo contrário, **modelos mais complexos estavam se tornando 'viciados' no ruído dos dados**. Eles estavam memorizando as particularidades do nosso conjunto de treino, em vez de aprender os padrões verdadeiros. Jogar mais poder computacional no problema não resolveria. Precisávamos de uma nova abordagem, uma que não buscasse o modelo mais potente, mas sim o mais inteligente e robusto – um modelo que soubesse ignorar o ruído e capturar apenas o sinal.

Conclusão do Capítulo: Este Sprint, embora não tenha atingido a meta de acurácia, foi talvez o mais importante de todos. Ele nos uniu como equipe, nos deu domínio completo sobre o significado dos dados com nossa própria legenda e, crucialmente, nos mostrou os limites da nossa abordagem. A busca pelo 0.700 não havia falhado; ela apenas nos mostrou que o caminho era outro. O próximo capítulo de nossa jornada seria focado em uma engenharia de features radicalmente nova, a verdadeira chave para destravar o potencial dos nossos dados.

Capítulo Final: A Revelação da Simplicidade - Encontrando a Estabilidade

A Encruzilhada: Performance vs. Confiabilidade

Após a busca exaustiva por uma acurácia acima de 0.700, que nos levou a modelos complexos e instáveis, a equipe chegou a uma encruzilhada. A pergunta mudou: em vez de "Qual o R^2 mais alto que podemos alcançar?", passamos a nos perguntar "**Qual o modelo mais confiável e estável que podemos construir?**". Essa mudança de mentalidade foi o ponto de virada definitivo do projeto.

A Nova Estratégia: Da Força Bruta à Inteligência Guiada

Com a certeza de que nosso desafio era combater o *overfitting* e o ruído nos dados, nossa estratégia mudou radicalmente. Abandonamos a busca por complexidade e nos voltamos para uma família de modelos conhecida por sua elegância e controle: os **modelos lineares com regularização**. A hipótese era que um modelo mais simples, mas aplicado a dados mais inteligentes, poderia superar um modelo complexo que operava em dados brutos.

1. O "Porquê" da Estratégia: A Aposta na Regularização

Primeiro, definimos a família de modelos. A regularização é uma técnica que penaliza a complexidade, forçando o modelo a ser mais "cético" e a focar apenas nas features com impacto real e consistente. Modelos como Lasso (L1), que pode zerar o impacto de features

irrelevantes, e Ridge (L2), que encolhe seus coeficientes, eram perfeitos para ignorar o ruído que nos atormentava. O ElasticNet combinava o poder de ambos.

2. O Enriquecimento dos Dados: Engenharia de Features Direcionada

Não nos limitamos às features originais. Acreditávamos que as relações entre as variáveis poderiam esconder insights valiosos que um modelo linear, por natureza, não capturaria sozinho. Com base em hipóteses de negócio, criamos um novo arsenal de features, incluindo:

Razão de Eficiência (Eficiencia_Performance): Calculada como $\text{Performance_Score} / \text{Tempo_Total}$, esta feature testava a hipótese de que um jogador que pontua alto em pouco tempo tem um perfil de comportamento diferente.

Interação Comportamental (Atitude_Consistente): Criada a partir da multiplicação do score de atitude (Likert_Score_Medio) pela consistência do jogador (Consistencia_F07), para testar se um jogador com atitude positiva e comportamento consistente era um preditor mais forte.

Relações Não-Lineares (Idade_Anos_Sq): Ao elevar a idade ao quadrado, permitimos que o modelo capturasse efeitos não lineares, como um possível declínio ou melhora de performance que se acentua com o envelhecimento.

3. A Seleção Científica: Deixando os Dados Falarem (RFECV)

Com um arsenal de features agora enriquecido (originais + criadas), o desafio era evitar adicionar complexidade desnecessária. Para isso, utilizamos a **Seleção Recursiva de Features com Validação Cruzada (RFECV)**. Essa técnica testa sistematicamente qual o subconjunto exato de features — tanto das originais quanto das recém-criadas — maximiza a performance preditiva de forma estável, nos dando o conjunto de preditores mais enxuto e poderoso possível.

O Veredito Final: Performance Confiável e Overfitting Controlado

A aposta se pagou. Os resultados desta abordagem final foram um divisor de águas, trazendo a estabilidade e a confiança que tanto buscávamos. Cada modelo especialista encontrou seu ponto de equilíbrio, entregando uma performance preditiva útil com um controle de overfitting exemplar:

- **Target 1: Estabilidade e Performance (Status: Excelente)**
 - **Modelo:** ElasticNet com apenas **13 features**.
 - **R² Final (Teste): 0.5670.**

- **Overfitting Controlado:** Uma diferença entre treino e teste de apenas **0.0860**.
- **Target 2: O Desafio Superado (Status: Excelente)**
 - **Modelo:** Lasso com **13 features**.
 - **R² Final (Teste): 0.4429**.
 - **Overfitting Mínimo:** Uma diferença impressionante de apenas **0.0104**.
- **Target 3: A Generalização Perfeita (Status: Perfeito)**
 - **Modelo:** Ridge com **20 features**.
 - **R² Final (Teste): 0.4645**.
 - **Overfitting Nulo:** Uma diferença praticamente inexistente de **0.0007**, um resultado tecnicamente perfeito em termos de generalização.

Tabela com os resultados finais:

Target	Melhor Modelo	R ² Final (Teste)	Overfitting (Diferença Train-Test)	Status
Target 1	ElasticNet (13 features)	0.5670	0.0860	Excelente
Target 2	Lasso (13 features)	0.4429	0.0104	Excelente
Target 3	Ridge (20 features)	0.4645	0.0007	Perfeito

A Verdadeira Medida de Sucesso: A Conclusão Correta

A conclusão desta jornada é a lição mais valiosa da ciência de dados: **o melhor modelo não é aquele com o R² mais alto, mas sim aquele em que se pode confiar.**

A análise final provou que a meta inicial de 0.700, para este conjunto de dados, era uma miragem que levava a modelos instáveis. Ao redefinir o sucesso como a busca pela **estabilidade e generalização**, o projeto alcançou scores moderados, porém extremamente robustos e defensáveis.

A escolha de modelos mais simples e regularizados (ElasticNet, Lasso, Ridge), combinada com uma seleção de features enxuta, não foi um passo para trás. Representou o ápice da maturidade analítica do projeto, priorizando a confiabilidade que é essencial para qualquer aplicação no mundo real.

Do Modelo à Aplicação: O Legado do Projeto

O sucesso deste projeto, portanto, transcende a métrica R². Ele se materializa no que foi construído:

1. **Modelos Preditivos Confiáveis:** Entregamos três modelos especialistas com overfitting praticamente nulo, prontos para operar de forma estável e previsível.

2. **Uma Conclusão Estratégica:** Mais do que um número, entregamos uma resposta. Provamos os limites de previsibilidade do problema e estabelecemos um benchmark de performance realista e honesto.
3. **Uma Solução Completa:** O trabalho culminou na construção de uma solução de ponta a ponta, com **frontend e backend**, capaz de consumir os artefatos dos nossos modelos e entregar previsões em uma aplicação funcional.

No final, a história desta jornada não é sobre a falha em atingir um número, mas sobre o sucesso em encontrar o **modelo certo para o problema certo**. A conclusão de que um modelo ElasticNet com R^2 de 0.567 e overfitting quase nulo é superior a um modelo complexo com R^2 de 0.65 e overfitting alto não é uma opinião; **é a conclusão tecnicamente correta e profissional**. O projeto entregou modelos confiáveis, uma aplicação completa e uma lição fundamental sobre a verdadeira natureza da modelagem preditiva.